Ενότητα 2: Λεκτική Ανάλυση

(Εισαγωγή και ad-hoc scanning)

Μ.Στεφανιδάκης

15-2-2017

Λεκτική Ανάλυση (Scanning)

- Ομαδοποίηση χαρακτήρων εισόδου σε σύμβολα (tokens) με συλλογική έννοια
- Σε κάθε σύμβολο αντιστοιχεί το κείμενο που έχει αναγνωριστεί (lexeme)
  - η ανάλυση δηλώσεων όπως `int i;` θα δώσει π.χ. τα tokens `K_INT` `IDENTIFIER` `K_SEMIC`
    - τα `K_INT` και `K_SEMIC` θα αντιπροσωπεύουν πάντα το κείμενο `int` και `;`
    - το `IDENTIFIER` αντιπροσωπεύει εδώ το `i` (σε άλλες δηλώσεις μεταβλητών θα αντιστοιχεί σε διαφορετικό κείμενο)
- Μείωση της πολυπλοκότητας του επόμενου σταδίου (συντακτική ανάλυση)

Λεκτική Ανάλυση: υλοποίηση

Η έννοια του αυτόματου πεπερασμένων καταστάσεων
Παράδειγμα: αναγνώριση των λέξεων test, term και long (και μόνον!)

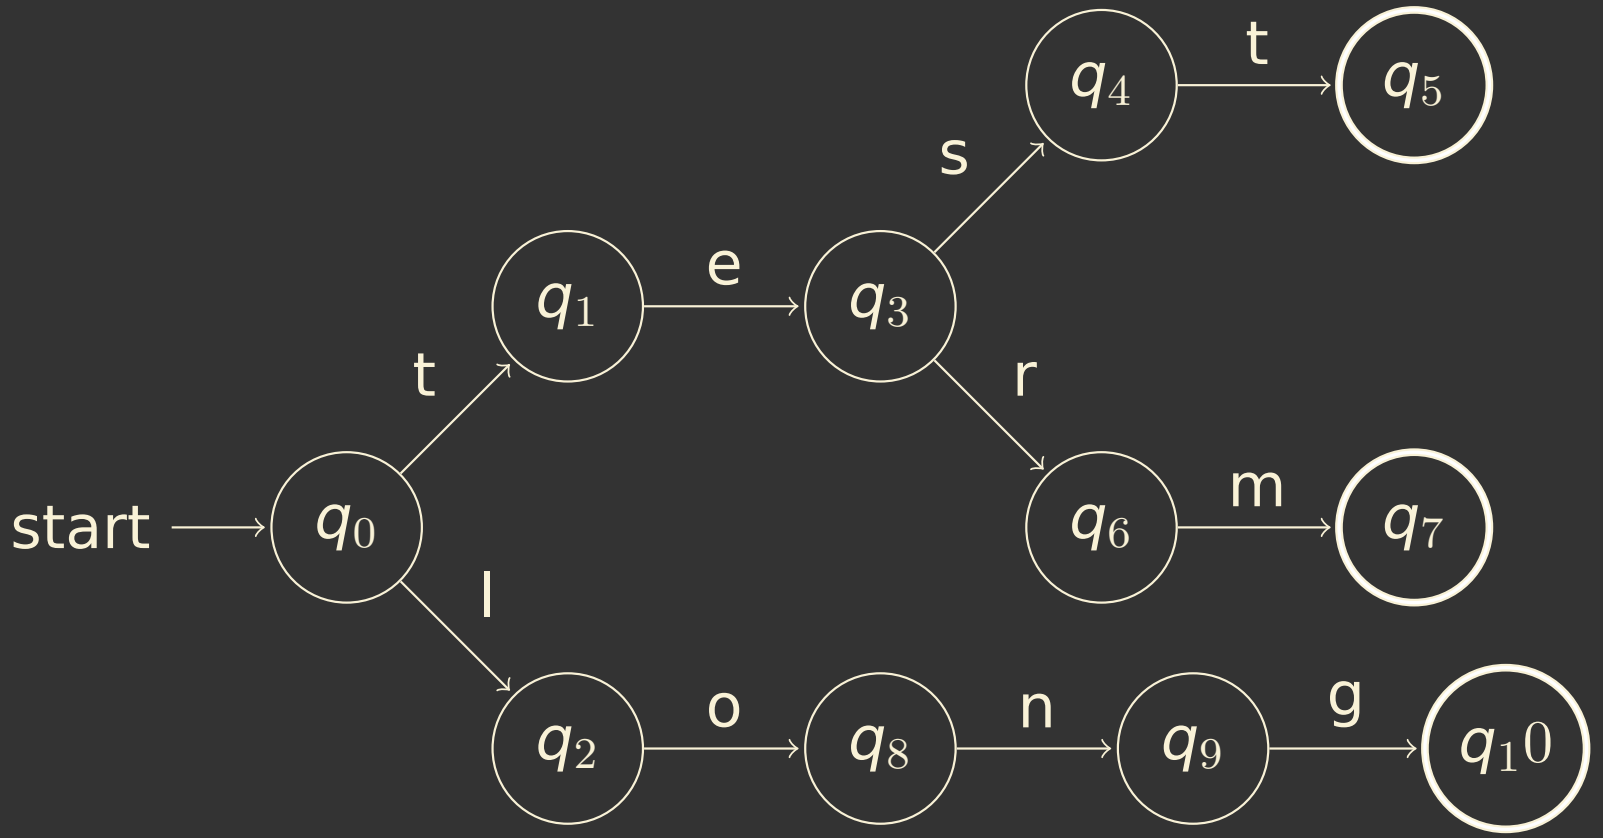

Πεπερασμένα Αυτόματα (Finite Automata –FA)

Από τη “Θεωρία Υπολογισμού”: FA είναι μια πεντάδα $(Q, \Sigma, \delta, q_0, F)$, όπου

- Q ένα πεπερασμένο σύνολο καταστάσεων
  - συν μια κατάσταση σφάλματος q_e
- Σ ένα πεπερασμένο αλφάβητο
  - σύνολο χαρακτήρων εισόδου
- $\delta: Q \times \Sigma \to Q$ η συνάρτηση μετάβασης
  - από την τρέχουσα στην επόμενη κατάσταση, με την εμφάνιση ενός νέου χαρακτήρα εισόδου
  - αν δεν υπάρχει μετάβαση, τότε σφάλμα
- $q_0 \in Q$ η αρχική κατάσταση
- $F \subseteq Q$ το σύνολο των καταστάσεων αποδοχής
  - εάν βρισκόμαστε εδώ όταν τελειώσει η ανάλυση, τότε αποδεχόμαστε το κείμενο εισόδου

Υλοποίηση με πίνακα μεταβάσεων

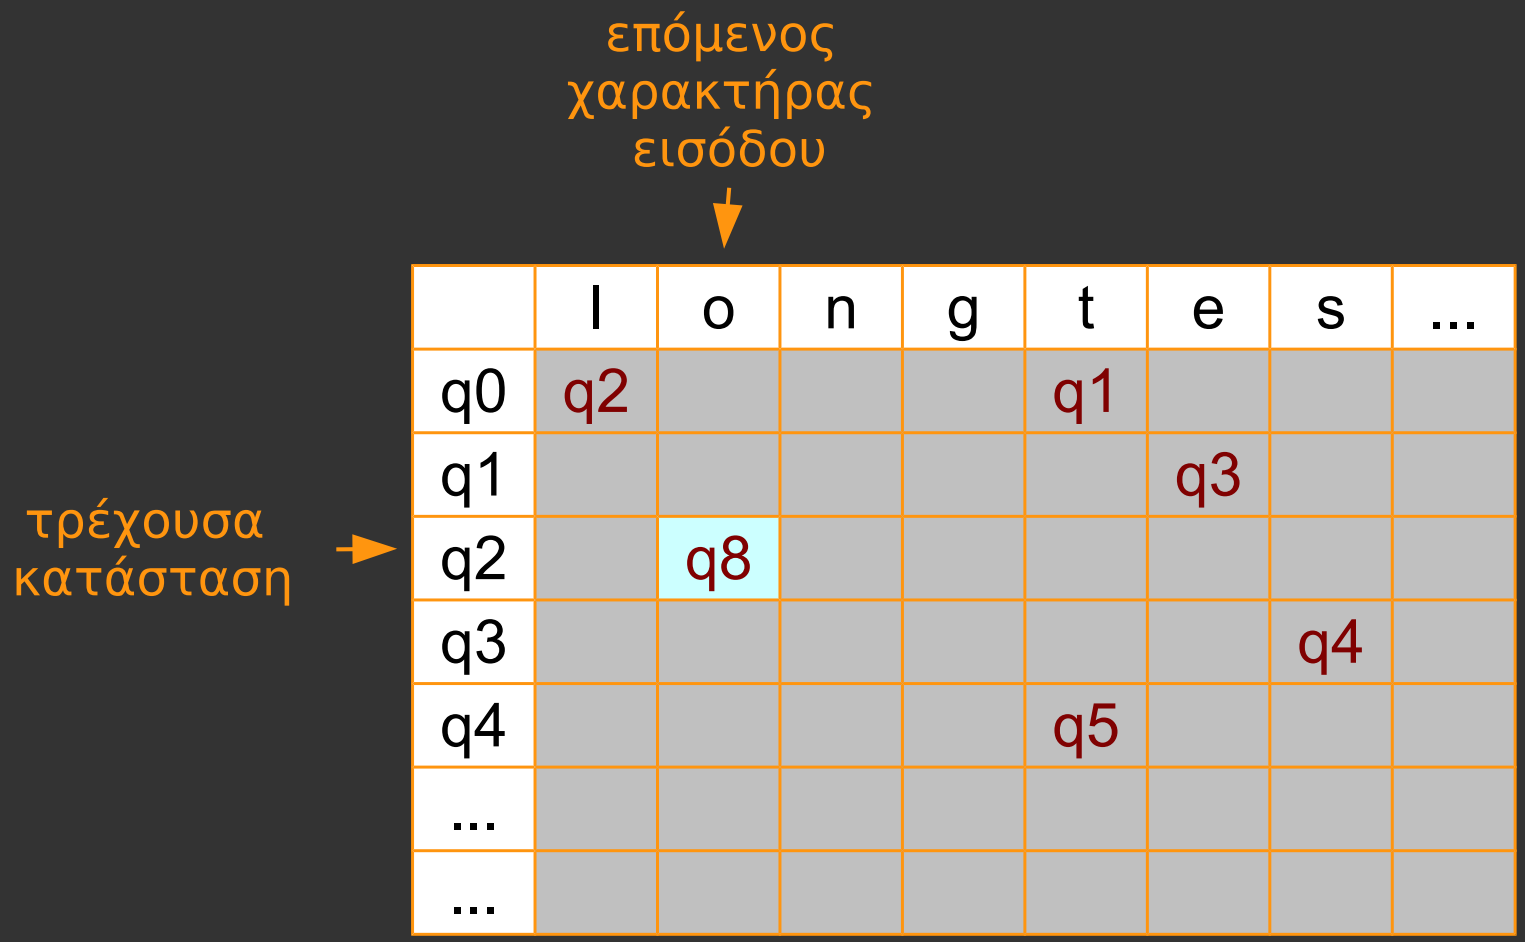

	l	o	n	g	t	e	s	...
q0	q2				q1			
q1						q3		
q2		q8						
q3							q4	
q4					q5			
...								
...								

καταστάσεις αποδοχής: q5, q7, ...

Παράδειγμα υλοποίησης

Ο πίνακας μεταβάσεων για τα `test`, `term` και `long`
(π.χ. στο state `s0`, αν εμφανιστεί ο χαρακτήρας `t`, μετάβαση στο state `s1`)

```
td = { 's0':{ 't':'s1','l':'s2' },
       's1':{ 'e':'s3' },
       's2':{ 'o':'s4' },
       's3':{ 's':'s5','r':'s6' },
       's4':{ 'n':'s7' },
       's5':{ 't':'s8f' },
       's6':{ 'm':'s9f' },
       's7':{ 'g':'s10f' },
     }
```

Παράδειγμα υλοποίησης (2)

Ο πίνακας καταστάσεων αποδοχής (accepting states) και το αντίστοιχο σύμβολο (token)

```
ad = { 's8f':'TEST_TOKEN',
       's9f':'TERM_TOKEN',
       's10f':'LONG_TOKEN'
     }
```

Παράδειγμα υλοποίησης (3)

Η συνάρτηση scan()

```
def scan(text,transition_table,accept_states):

    # initial state
    pos = 0
    state = 's0'

    while True:
        c = getchar(text,pos)    # get next char

        if c in transition_table[state]:
            state = transition_table[state][c]    # set new st
            pos += 1    # advance to next char

            # check if new state is accepting
            if state in accept_states:
                return accept_states[state],pos

        else:    # no transition found
            return 'ERROR',pos
```

Επεκτάσεις προηγούμενου κώδικα

- Μελετήστε πρώτα και δοκιμάστε να εκτελέσετε τον πλήρη κώδικα του παραδείγματος
- Η σειρά σας: αναγνωρίστε τις λέξεις `today` και `tomorrow`
- Αν επιθυμούμε το μέγιστο δυνατό ταίριασμα;
  - Δεν γίνεται με τον προηγούμενο κώδικα...
  - Υπόδειξη: επιστρέφουμε μόνο όταν δεν υπάρχουν άλλες μεταβάσεις
    - Μόνο τότε ελέγχουμε αν βρισκόμαστε σε κατάσταση αποδοχής
  - Η σειρά σας: κατασκευάστε λεκτικό αναλυτή που αναγνωρίζει
    - ακεραίους (σειρά από ψηφία 0-9, `INT_TOKEN`)

Επεκτάσεις προηγούμενου κώδικα (2)

- Αν απαιτούνται προαιρετικά (optional) ταιριάσματα;
  - Υπόδειξη: Θυμόμαστε την τελευταία κατάσταση αποδοχής από την οποία έχουμε περάσει
    - Και αν φτάσουμε σε αδιέξοδο, επιστρέφουμε εκείνη
  - Η σειρά σας: κατασκευάστε λεκτικό αναλυτή που αναγνωρίζει
    - ακεραίους (σειρά από ψηφία 0-9, `INT_TOKEN`)
    - κλασματικούς (σειρά από ψηφία 0-9, μία τελεία και σειρά από ψηφία 0-9, `FLOAT_TOKEN`)