

Ιόνιο Πανεπιστήμιο – Τμήμα Πληροφορικής
Εισαγωγή στην Επιστήμη των Υπολογιστών
2016-17

Αναπαράσταση Μη Αριθμητικών Δεδομένων

(κείμενο, ήχος και εικόνα στον υπολογιστή)

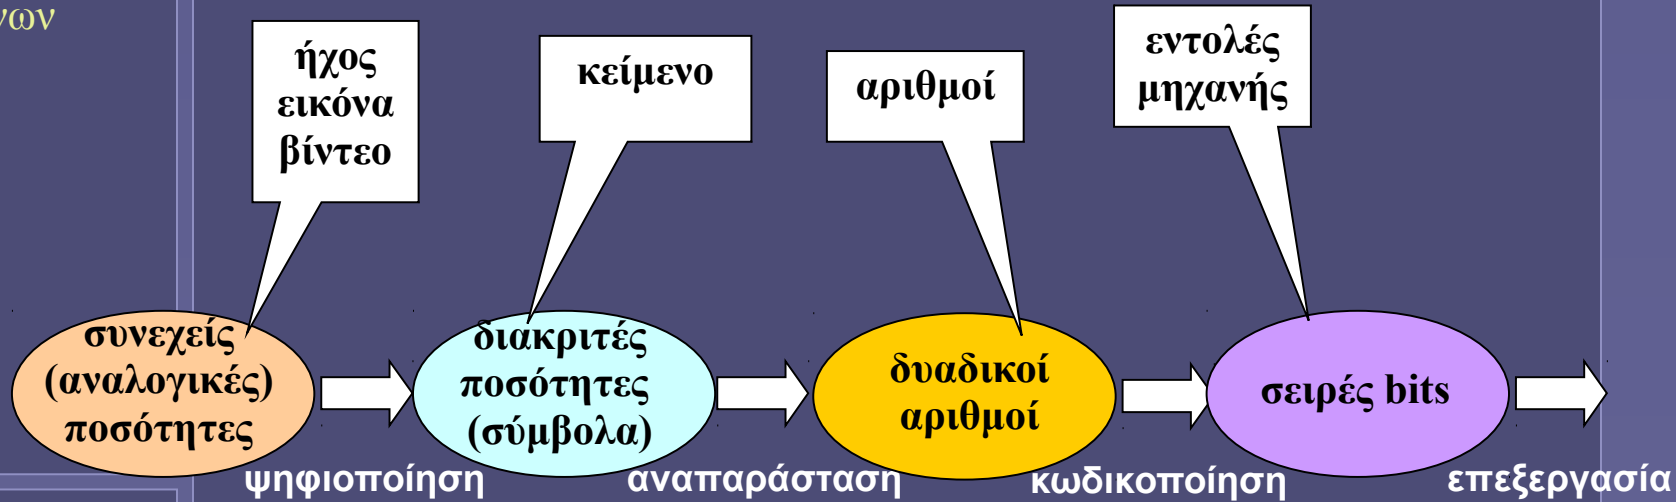
<http://mixstef.github.io/courses/csintro/>

Μ.Στεφανιδάκης



Αναπαράσταση δεδομένων

- Αναπαράσταση δεδομένων



!

Δεδομένα:
ανεξάρτητα από
τύπο και
προέλευση, στον
υπολογιστή
υπάρχουν σε μία
μορφή: 0 και 1

- Ψηφιοποίηση
 - Διαδικασία μετατροπής συνεχών τιμών σε διακριτά σύμβολα
- Αναπαράσταση
 - Διαδικασία αντιστοίχισης συμβόλων σε δυαδικούς αριθμούς
- Κωδικοποίηση
 - Αποθήκευση δυαδικών αριθμών σε σειρές bits

Η ερμηνεία της αναπαράστασης

- Αναπαράσταση δεδομένων

!

Στα ερωτήματα αυτά μπορεί να απαντήσει μόνο ο προγραμματιστής της εφαρμογής που χειρίζεται τα δεδομένα!

- Κάπου στη μνήμη του υπολογιστή...
 - Βρίσκεται αποθηκευμένη η σειρά bits
0100110111010001
- Πόσα σύμβολα αναπαριστά;
 - Πόσα bits ανά σύμβολο;
- Ποιος ο τύπος των δεδομένων;
- Ποια συγκεκριμένη ποσότητα συμβολίζει;
- Πώς θα το χειριστεί ο υπολογιστής;

Αναπαράσταση με δυαδικούς αριθμούς

- Αναπαράσταση δεδομένων

- Σειρά n bits

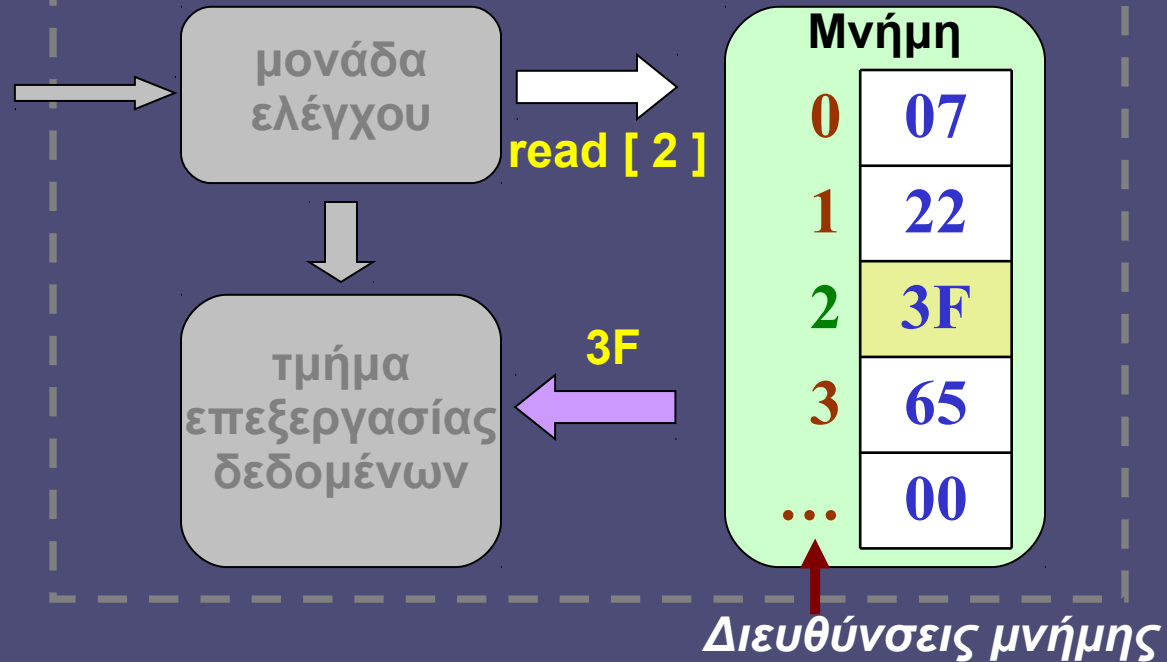
- Δυαδικός αριθμός με n bits ($n \geq 1$) μπορεί να αναπαραστήσει 2^n διαφορετικά σύμβολα

- Μη αριθμητικά δεδομένα

- Κείμενο, εντολές μηχανής, ήχος, εικόνα...
 - Σύνολο διαφορετικών αντικειμένων (συμβόλων)
- Αντιστοίχιση κάθε συμβόλου σε μοναδικό δυαδικό αριθμό (code point)
 - “Αναπαράσταση”
 - Η ακριβής αντιστοίχιση συνήθως ορίζεται σε ένα πρότυπο (standard)

Η επικοινωνία με τη μνήμη

- Αναπαράσταση δεδομένων



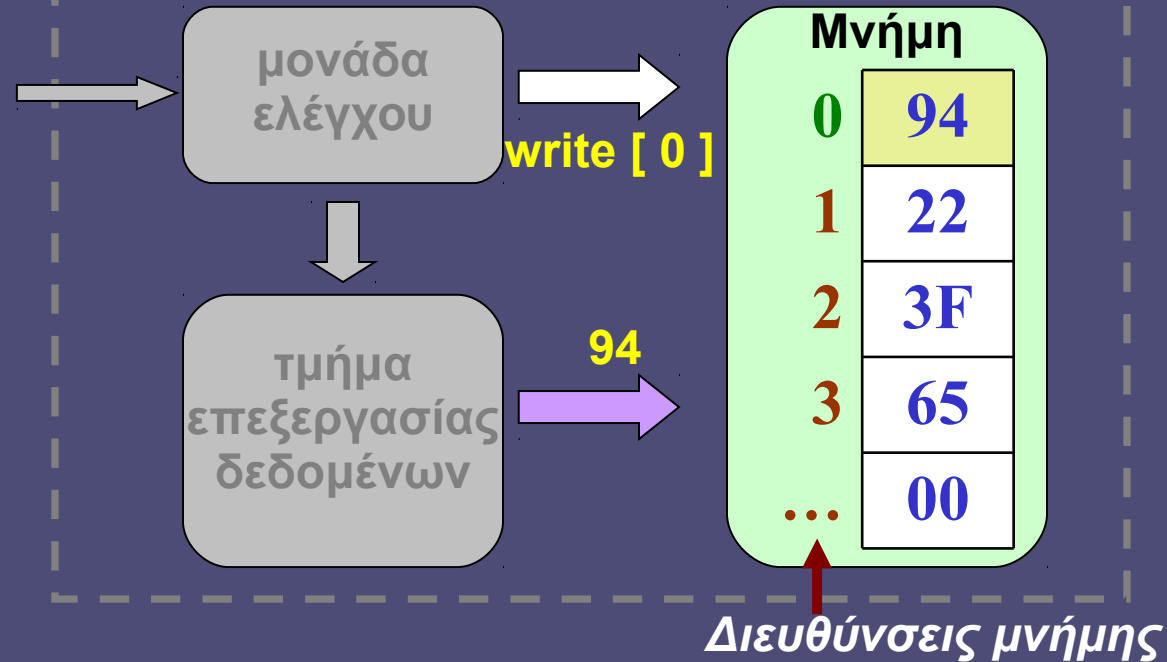
- Μοντέλο μνήμης
 - Συστοιχία αποθηκευτικών θέσεων
 - Σε κάθε θέση αποθηκεύεται (συνήθως) 1 byte
 - Κάθε θέση διαθέτει μοναδική διεύθυνση
 - Επιλογή θέσης κατά την προσπέλαση (ανάγνωση-εγγραφή)

Η επικοινωνία με τη μνήμη

- Αναπαράσταση δεδομένων

•
;

Με διεύθυνση των n bits, πόσες διαφορετικές θέσεις μνήμης μπορούμε να προσπελάσουμε;



- Χωρητικότητα μνήμης
 - Εκφράζεται σε πολλαπλάσια του byte
 - 1 KByte (KB) = 1024 Bytes (2^{10})
 - 1 MByte (MB) = 1024 KBytes (2^{10})
 - κλπ

Θέματα αποθήκευσης δυαδικών αριθμών

- Αναπαράσταση δεδομένων

;

Πώς σχετίζεται η σειρά αποθήκευσης των bytes με τα “Ταξίδια του Γκιούλιβερ”;

- Όταν
 - Ένας δυαδικός αριθμός χρειάζεται περισσότερα από ένα byte για να αποθηκεύσει τα ψηφία του
- Παράδειγμα: 3FC (hex) = 11 1111 1100
Χρειάζονται 2 bytes!

0000 0011 1111 1100

περισσότερο σημαντικό byte λιγότερο σημαντικό byte
- Προφανώς σε συνεχόμενες θέσεις μνήμης
Αλλά: ποιο byte αποθηκεύεται πρώτο;

Θέματα αποθήκευσης δυαδικών αριθμών


- Αναπαράσταση δεδομένων

αποθηκεύοντας το
03FC

00000011 11111100


i

Στο Διαδίκτυο τα
δεδομένα
διακινούνται σε
big-endian μορφή



“little-endian”

Το λιγότερο σημαντικό
byte στη θέση μνήμης
με μικρότερη
διεύθυνση



“big-endian”

Το περισσότερο σημαντικό
byte στη
θέση μνήμης με
μικρότερη διεύθυνση

Αρχικές αναπαραστάσεις κειμένου

- Αναπαράσταση δεδομένων
- Κείμενο

- **Οι πρώτες αναπαραστάσεις κειμένου**
 - Στον υπολογιστή
 - 6-7 bits ανά χαρακτήρα
 - Πόσοι διαφορετικοί χαρακτήρες;
- **Μη εκτυπώσιμοι χαρακτήρες**
 - Χαρακτήρες ελέγχου
 - Ιδιαίτερα χρήσιμοι για τις συσκευές εξόδου της εποχής (εκτυπωτές, τηλέτυπα...)
 - Νέα γραμμή (LINE FEED – LF)
 - Επιστροφή κεφαλής εκτύπωσης (CARRIAGE RETURN – CR)
 - Καμπανάκι (BELL) κλπ

Κώδικας ASCII

- Αναπαράσταση δεδομένων
- Κείμενο

- Βασικό αρχικό πρότυπο αναπαράστασης κειμένου
 - 7 bits ανά χαρακτήρα

STANDARD ASCII ΚΩΔΙΚΑΣ

hex	char	hex	char	hex	char
20		40	@	60	'
21	!	41	A	61	a
22	"	42	B	62	b
23	#	43	C	63	c
24	\$	44	D	64	d
25	%	45	E	65	e
26	&	46	F	66	f
27	'	47	G	67	g
28	(48	H	68	h
29)	49	I	69	i
2A	*	4A	J	6A	j
2B	+	4B	K	6B	k
2C	,	4C	L	6C	l
2D	-	4D	M	6D	m
2E	.	4E	N	6E	n
2F	/	4F	O	6F	o

1

ASCII: American
Standard Code for
Information
Interchange

Κείμενο σε κώδικα ASCII

- Αναπαράσταση δεδομένων
- Κείμενο

;

Με 7 bits ανά χαρακτήρα και χρήση bytes, 1 bit μένει αχρησιμοποίητο. Πόσοι επιπλέον χαρακτήρες με το bit αυτό;

- 7 bits ανά χαρακτήρα
 - 128 χαρακτήρες
 - Αναπαράσταση με τους αριθμούς 0...127
- Κανονικοί χαρακτήρες (εκτυπώσιμοι)
 - 32...64, 91...96, 123...126 = σημεία στίξης κ.ά. (32 = SPACE!)
 - 65...90 = κεφαλαία λατινικά (A-Z)
 - 97...122 = πεζά λατινικά (a-z)
- Χαρακτήρες ελέγχου (μη εκτυπώσιμοι)
 - 0...31, 127 – επιζούν τα: 9 (TAB), 13/10 (CR/LF, σήμανση “νέας γραμμής”)

Κείμενο σε κώδικα ASCII

- Αναπαράσταση δεδομένων
- Κείμενο

!

Εφόσον η κωδικοποίηση είναι με 1 byte ανά χαρακτήρα, δεν τίθεται θέμα “little-” ή “big-endian”

- Παράδειγμα

H	a	v	e		a		n	i	c	e		d	a	y	!
72	97	118	101	32	97	32	110	105	99	101	32	100	97	121	33

- Γλώσσες προγραμματισμού
 - Συμβολοσειρά (string)
 - Σε γλώσσες όπως η C, το 0 (αριθμητικό) συμβολίζει το τέλος της συμβολοσειράς
 - Ο υπολογιστής μπορεί να κάνει πράξεις (π.χ. σύγκριση) με τη συμβολοσειρά

Επεκτάσεις κώδικα ASCII

- Αναπαράσταση δεδομένων
- Κείμενο



Χρησιμοποιώντας τον ISO-8859-1 δεν είναι δυνατή η αναπαράσταση των ελληνικών!

- Χρήση του 1 επιπλέον bit του byte
 - 128 + 128 χαρακτήρες, αριθμοί 0...255
 - 0...127 αντιστοιχούν στον αρχικό ASCII
 - 127...255: επεκταμένα αλφάβητα
- Επέκταση αλφαβήτων (πρότυπα)
 - Χαρακτήρες που δεν υπάρχουν στον ASCII
 - Διαφορετικά ανά γλώσσα! Π.χ.:
 - ISO-8859-1: Δυτική Ευρώπη (Å, Ñ, Æ, ä, ø κλπ)
 - ISO-8859-7: Νέα Ελληνικά
 - ...και πολλά άλλα πρότυπα για τις υπόλοιπες γλώσσες
 - Επίσης: μη πρότυπες λύσεις
 - Για Windows, Mac ..

Κώδικας ISO-8859-7

- Αναπαράσταση δεδομένων
- Κείμενο

	x0	x1	x2	x3	x4	x5	x6	x7	x8	x9	xA	xB	xC	xD	xE	xF
0x	<i>unused</i>															
1x																
2x	SP	!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3x	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4x	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5x	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6x	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7x	p	q	r	s	t	u	v	w	x	y	z	{		}	~	
8x	<i>unused</i>															
9x																
Ax	NBSP	·	´	£	€	Ɔp		§	¨	©	,	*	¬	SHY		—
Bx	°	±	²	³	´	ˆ	À	Á	Â	Ã	Ä	Å	Ö	½	Υ	Ω
Cx	ΐ	Α	Β	Γ	Δ	Ε	Ζ	Η	Θ	Ι	Κ	Λ	Μ	Ν	Ξ	Ο
Dx	Π	Ρ		Σ	Τ	Υ	Φ	Χ	Ψ	Ω	Ϊ	Ϋ	ά	έ	ή	ί
Ex	ὀ	α	β	γ	δ	ε	ζ	η	θ	ι	κ	λ	μ	ν	ξ	ο
Fx	π	ρ	ς	σ	τ	υ	φ	χ	ψ	ω	ϊ	ϋ	ό	ύ	ώ	

[Wikipedia]

Κείμενο σε κώδικα ISO-8859-7

- Αναπαράσταση δεδομένων
- Κείμενο

- Παράδειγμα

Γ	ε	ι	α		σ	ο	υ	!
195	229	233	225	32	243	239	245	33

- Επέκταση κώδικα ASCII

- 0...127 όπως στον ASCII
- 128...159 πρόσθετοι χαρακτήρες ελέγχου
- 160...255 ελληνικά και σχετικά σύμβολα

!

Οι
αναπαραστάσεις
αλφαβήτων με 1
byte ανά
χαρακτήρα τείνουν
να καταργηθούν!

Πρότυπο Unicode

- Αναπαράσταση δεδομένων
- Κείμενο



Με περισσότερα από 1 bytes ανά χαρακτήρα τίθεται θέμα **σειράς αποθήκευσης** των bytes!

- Για την αναπαράσταση όλων των αλφαβήτων!
 - Έχουν οριστεί σχεδόν 100.000 χαρακτήρες
 - Καλύπτει ιδεογράμματα, φωνητικές αναπαραστάσεις κλπ
 - Θα μπορούσε να καλύψει πάνω από 1 εκ. χαρακτήρες! (0 ... 10FFFF)
 - Κάθε χαρακτήρας αναπαρίσταται με **περισσότερα από ένα bytes**
 - Συνήθεις κωδικοποιήσεις: UCS-2 (ή UTF-16) και UTF-8
 - Το πρότυπο Unicode περιέχει επίσης
 - πληροφορία ισοδύναμων ή παρόμοιων χαρακτήρων
 - οδηγίες συνδυασμών τόνων/διακριτικών και γραμμάτων

Ελληνικά και Unicode

- Αναπαράσταση δεδομένων
- Κείμενο

Greek and Coptic									03FF
	037	038	039	03A	03B	03C	03D	03E	03F
0			ι̇ 0390	Π 03A0	Ϝ 03B0	π 03C0	β 03D0	Ϡ 03E0	Ϻ 03F0
1			Α 0391	Ρ 03A1	α 03B1	ρ 03C1	ϑ 03D1	ϡ 03E1	ϙ 03F1
2			Β 0392		β 03B2	ς 03C2	Υ 03D2	Ϸ 03E2	ϣ 03F2
3			Γ 0393	Σ 03A3	γ 03B3	σ 03C3	Ύ 03D3	ϸ 03E3	ϛ 03F3
4	΄ 0374	΄ 0384	Δ 0394	Τ 03A4	δ 03B4	τ 03C4	Ύ̇ 03D4	Ϣ 03E4	Θ 03F4
5	΄ 0375	Ⲁ 0385	Ε 0395	Υ 03A5	ε 03B5	υ 03C5	ϕ 03D5	ϣ 03E5	Ε 03F5
6		Α̇ 0386	Ζ 0396	Φ 03A6	ζ 03B6	φ 03C6	ω 03D6	ϡ 03E6	ϣ 03F6

Κείμενο σε Unicode

- Αναπαράσταση δεδομένων
- Κείμενο

Παράδειγμα

δεκαεξαδικό

Γ	ε	ι	α		σ	ο	υ	!
915	949	953	945	32	963	959	965	33
0393	03B5	03B9	03B1	0020	03C3	03BF	03C5	0021

Κωδικοποίηση UCS-2 (big-endian)

03	93	03	B5	03	B9	03	B1	00	20	03	C3	03	BF	03	C5	00	21
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----

Κωδικοποίηση UCS-2 (little-endian)

93	03	B5	03	B9	03	B1	03	20	00	C3	03	BF	03	C5	03	21	00
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----

Unicode σε κωδικοποίηση UTF-8

- Αναπαράσταση δεδομένων
- Κείμενο



Η κωδικοποίηση UTF-8 τείνει να επικρατήσει σε όλα τα προγράμματα που χειρίζονται κείμενα Unicode!


• Αναπαράσταση μεταβλητού μήκους

Unicode	Κωδικοποίηση UTF-8
00...7F	0xxxxxxx
80...7FF	110xxxxx 10xxxxxx
800...FFFF	1110xxxx 10xxxxxx 10xxxxxx
10000...10FFFF	11110xxx 10xxxxxx 10xxxxxx 10xxxxxx

- Το βασικό λατινικό αλφάβητο (ASCII)
χρησιμοποιεί 1 byte ανά χαρακτήρα
 - Προς τα πίσω συμβατότητα
- Τα ελληνικά, 2 bytes
 - Ποια η κωδικοποίηση κατά UTF-8 του τελευταίου παραδείγματος;


Ήχος: Ψηφιοποίηση και Αποθήκευση

- Αναπαράσταση δεδομένων
- Κείμενο
- Ήχος




Εικόνα: από τον αναλογικό στον ψηφιακό κόσμο

- Αναπαράσταση δεδομένων
- Κείμενο
- Ήχος
- Εικόνα



- Φωτοευαίσθητα κύτταρα
 - για τρία χρώματα (κόκκινο-πράσινο-μπλε)
- Μετατροπή σήματος σε ψηφιακή πληροφορία

Παράδειγμα: απλή αναπαράσταση pixels με 16,7 εκ. χρώματα



R:144 G:128 B:118	R:193 G:164 B:179	...
R:201 G:174 B:134
...

1 pixel

- 3 bytes/pixel (24bits): **R**(ed) **G**(reen) **B**(lue)
 - 256 στάθμες ανά συνιστώσα χρώματος
 - $256 \times 256 \times 256 = 16.777.216$ χρώματα
 - εικόνες με μεγαλύτερο βάθος χρώματος
 - 32 έως 48 bits

Εναλλακτικά: διανυσματικά γραφικά

- Αναπαράσταση δεδομένων
- Κείμενο
- Ήχος
- Εικόνα

- Περιγραφή σχημάτων
 - Ως σύνολο ευθύγραμμων και καμπύλων τμημάτων
 - Με συντεταγμένες
 - Εύρεση σημείων μέσω μαθηματικού τύπου
- Εύκολη αλλαγή μεγέθους γραφικών
 - Χωρίς παραμόρφωση των σχημάτων

Αναπαράσταση βίντεο

- Αναπαράσταση δεδομένων
 - Κείμενο
 - Ήχος
 - Εικόνα
 - Βίντεο
- “Κινούμενη εικόνα” (καρέ)
 - όπως αναπαριστούμε τις απλές εικόνες
 - αλλά: με χρήση συμπίεσης
 - Για μείωση όγκου δεδομένων
 - Γειτονικά καρέ έχουν πολλές ομοιότητες

Κωδικοποίηση εντολών μηχανής

- Αναπαράσταση δεδομένων
- Κείμενο
- Ήχος
- Εικόνα
- Βίντεο
- Εντολές Μηχανής

