


Εργαστήριο Σημασιολογικού Ιστού

Ενότητα 5: Resource Description Framework (RDF)

Μ.Στεφανιδάκης

15-3-2017

Τα επίπεδα του Σημασιολογικού Ιστού




RDF: Το κύριο πρότυπο του Σημασιολογικού Ιστού, χρησιμοποιεί αναγνωριστικά URIs

Resource Description Framework (RDF)

- ▶ Βασικό πρότυπο του Σημασιολογικού Ιστού
- ▶ Αν και λέμε συχνά “η RDF” (υπονοώντας “η γλώσσα RDF”)
- ▶ Στην πραγματικότητα είναι ένα μοντέλο οργάνωσης γνώσης
 - ▶ Που επιτρέπει να κάνουμε δηλώσεις (statements)
 - ▶ σε μορφή τριάδων (triples) (και του αντίστοιχου γράφου (graph))
 - ▶ σχετικά με οντότητες (resources)
 - ▶ οι οποίες συμβολίζονται με URIs
- ▶ Από τα πρώτα πρότυπα, με μια πιο πρόσφατη επανέκδοση (2014)
 - ▶ Τα εργαλεία/βιβλιοθήκες RDF ίσως να μην έχουν ενημερωθεί ακόμα!

Μοντέλο δεδομένων κατά το πρότυπο RDF

- ▶ Η RDF προσδιορίζει ένα μοντέλο (abstract syntax) βασισμένο στις τριάδες, ακριβώς όπως τις έχουμε δει ως τώρα
 - ▶ (υποκείμενο **s**, κατηγορημα **p**, αντικείμενο **o**)
 - ▶ ως μέρος γράφου με δύο κόμβους (s,o) και μία κατευθυνόμενη ακμή (από το s προς το o)
 - ▶ οι κόμβοι μπορούν να είναι URIs (IRIs), ανώνυμοι (blank nodes) ή σταθερές (literals)
- ▶ Το p δηλώνει μια **ιδιότητα** (property), μια διμερή δηλαδή **σχέση** (binary relation) μεταξύ s και o



URIs, blank nodes και literals

- ▶ Τα **URIs** δρουν ως σφαιρικά αναγνωριστικά οντοτήτων
 - ▶ Ένα URI δεν πρέπει ποτέ να αναφέρεται σε περισσότερες από μία οντότητα
 - ▶ Ένα URI, άπαξ και δημιουργηθεί, δεν πρέπει ποτέ να αλλάξει οντότητα, στην οποία αναφέρεται
 - ▶ Αν και δεν είναι υποχρεωτικό, ένα URI **καλό θα ήταν** να οδηγεί σε κάποιο έγγραφο στο web, με πληροφορία σχετική με την οντότητα του URI
- ▶ Οι ανώνυμοι κόμβοι (**blank nodes**) δεν αναγνωρίζουν οντότητες με ρητό όνομα
 - ▶ απλά λένε ότι κάτι (ανώνυμο) έχει τις περιγραφόμενες σχέσεις
- ▶ Οι σταθερές **literal** έχουν εξ'ορισμού τιμές που δεν αλλάζουν
 - ▶ Η RDF όμως τους προσδίδει **τύπο δεδομένων** (datatype)!

Datatypes

- ▶ Συμβολίζονται με ένα URI, συνήθως της μορφής:
- ▶ <http://www.w3.org/2001/XMLSchema#xxx>
 - ▶ xxx είναι ο εκάστοτε τύπος δεδομένων
 - ▶ βασίζεται στο πρότυπο XML Schema
 - ▶ συντομογραφικά: **xsd:xxx**
- ▶ Η RDF περιγράφει μια σειρά συμβατών τύπων δεδομένων
 - ▶ xsd:string, xsd:boolean, xsd:integer, xsd:double, xsd:float,...
 - ▶ xsd:date, xsd:time, xsd:dateTime,...
 - ▶ Κ.Ο.Κ..
- ▶ Η RDF χρησιμοποιεί επίσης το URI
 - ▶ <http://www.w3.org/1999/02/22-rdf-syntax-ns#langString>
 - ▶ για κείμενο με ένδειξη γλώσσας (π.χ. en, el, el-GR ..)

Literals και Datatypes

- ▶ Τι προσδίδει η σύνδεση ενός literal με έναν τύπο δεδομένων;
 - ▶ Προσδιορίζει τη μέθοδο **χειρισμού** της τιμής του literal
 - ▶ Πώς το κείμενο του literal (lexical form) θα μετατραπεί στην κατάλληλη τιμή
 - ▶ Η μετατροπή προσδιορίζεται από τον τύπο δεδομένων!
- ▶ Παράδειγμα: ο τύπος xsd:boolean
 - ▶ Διαθέτει δύο τιμές (**value space**): {true, false}
 - ▶ Δέχεται τα εξής strings (**lexical space**): {"true", "false", "1", "0"}
 - ▶ Μετατρέπει ως εξής (**Lexical-to-value mapping**):
< "true" → true >, < "false" → false >, < "1" → true >, < "0" → false >

Πηγές RDF και συλλογές γράφων RDF

► RDF Source

- Πηγή πληροφορίας RDF, περιέχει συλλογές γράφων RDF σε δεδομένη χρονική στιγμή
- Οι γράφοι (και οι τριάδες) που περιέχει μπορούν να αλλάξουν με την πάροδο του χρόνου

► RDF Dataset

- Μια συλλογή γράφων RDF, όπου
 - όλοι οι γράφοι **εκτός από έναν** αναγνωρίζονται με ένα URI (ή blank node) και ονομάζονται **επώνυμοι γράφοι** (named graphs)
 - Ο μοναδικός γράφος χωρίς σύνδεση με κάποιο URI είναι ο γράφος **default**
- Οι επώνυμοι γράφοι χρησιμοποιούνται για την τοποθέτηση των τριάδων σε υποσύνολα
 - Η χρήση τους προσδιορίζεται από την εκάστοτε εφαρμογή

Χώροι ονομάτων RDF

- ▶ Η RDF (και το συνοδευτικό RDFS που θα δούμε σε επόμενα) χρησιμοποιούν δικά τους (built-in) λεξιλόγια (vocabularies)
 - ▶ Για την “οντολογική” περιγραφή των διαφόρων οντοτήτων
 - ▶ Και για μια σειρά πρόσθετων βοηθητικών εννοιών (utilities)
- ▶ Οι χώροι ονομάτων για τα λεξιλόγια αυτά είναι
 - ▶ <http://www.w3.org/1999/02/22-rdf-syntax-ns#> (συντομογραφικό πρόθεμα **rdf**)
 - ▶ <http://www.w3.org/2000/01/rdf-schema#> (συντομογραφικό πρόθεμα **rdfs**)
- ▶ Παράδειγμα: `rdfs:label`
 - ▶ Χρησιμοποιείται για να συνδέσει μια ετικέτα αναγνώσιμη από τον άνθρωπο σε μια οντότητα
 - ▶ (<http://ex.com/A>, `rdfs:label`, “Semantic Web”@en)

Αποθήκευση δεδομένων RDF

- ▶ Η RDF εκτός από το μοντέλο οργάνωσης, περιγράφει και διάφορα μορφότυπα αποθήκευσης των τριάδων σε αρχεία κειμένου
- ▶ Το απλούστερο από τα μορφότυπα αυτά ονομάζεται **N-Triples**
 - ▶ Ξεκίνησε ως “η γλώσσα των παραδειγμάτων” της RDF
 - ▶ Αλλά πολύ γρήγορα χρησιμοποιήθηκε για **μαζική ανταλλαγή** δεδομένων RDF
 - ▶ **Πολύ απλή επεξεργασία**, δεν χρειάζονται εξειδικευμένες βιβλιοθήκες
 - ▶ Σήμερα υποστηρίζει Unicode χαρακτήρες (κωδικοποίηση utf-8)
 - ▶ Αρχικά, μόνο ASCII χαρακτήρες: όλοι οι άλλοι χρειαζόνταν ειδική κωδικοποίηση

N-Triples: βασική σύνταξη

- ▶ Κάθε γραμμή του αρχείου περιέχει ακριβώς μία τριάδα
 - ▶ Στη μορφή `s p o` . (κενά/tab μετά από κάθε ένα `s,p,o`, στη συνέχεια ακολουθεί τελεία και newline)
 - ▶ Στη συνιστώμενη κανονική μορφή: ακριβώς ένα κενό
- ▶ Τα URIs γράφονται μεταξύ `<` και `>`
 - ▶ `<http://ex.com/A>`
 - ▶ σε πλήρη μορφή, χωρίς συντομογραφικά προθέματα
- ▶ Τα **literals** γράφονται μεταξύ `"` και `"`
 - ▶ `"Semantic Web"`
 - ▶ Προαιρετικά ακολουθεί ο τύπος δεδομένων ή η γλώσσα

`"Semantic Web"@en`

`"1.663E-4"^^<http://www.w3.org/2001/XMLSchema#double>`

N-Triples: βασική σύνταξη (2)

- ▶ Οι ανώνυμοι κόμβοι (blank nodes) έχουν πρόθεμα _:
 - ▶ _:b1234
 - ▶ Μετά το _: ακολουθεί η ετικέτα του ανώνυμου κόμβου
 - ▶ Η τελεία δεν μπορεί να είναι στην αρχή ή το τέλος της ετικέτας
 - ▶ Το - δεν μπορεί να είναι στην αρχή της ετικέτας

Η σειρά σας!

- ▶ Ξεκινήστε από τα δεδομένα του ωρολογίου προγράμματος (σε μορφή csv τριάδων)
- ▶ Όπως έχει διαμορφωθεί μετά την εισαγωγή των URIs
 - ▶ Θα χρησιμοποιήσετε τύπο δεδομένων xsd:time (hh:mm:ss) για την ώρα
 - ▶ Χρησιμοποιήστε ώρα έναρξης και λήξης
- ▶ Στη συνέχεια, τροποποιήστε το πρόγραμμα που κατασκευάζει το csv των τριάδων
 - ▶ Για να παράγει αρχείο N-Triples!